



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)
دانشکده ریاضی و علوم کامپیوتر

پروژه درس جبر خطی عددی: استخراج ویژگی های بافت با استفاده از ماتریس
های هم رخدادی سطوح خاکستری (GLCM)

نگارش
آریان فتحی
۴۰۰۱۳۰۲۳

استاد درس
دکتر مهدی دهقان

دی ۱۴۰۳

چکیده

یکی از دغدغه‌های موجود در پردازش تصویر دیجیتال، کشف جنس سطوح و بافت‌ها^۱ از طریق الگوریتم‌های کامپیوتری است، این تحلیل‌ها در سه دسته‌ی کلی آماری^۲، ساختاری^۳ و طیفی^۴ قرار می‌گیرند. از معروف‌ترین روش‌های آماری می‌توان به ساخت ماتریس‌های هم‌رخدادی سطوح خاکستری و معیارهای آماری ای که طبق مقاله‌ی آقای رابرت هارالیک^۵ و همکارانش در سال ۱۹۷۳ میلادی منتشر کردند، اشاره کرد. آقای هارالیک در مقاله‌ی خود به ۱۴ معیار آماری اشاره کرده‌اند که همه‌ی آنها در سه دسته‌ی کلی کانترست، نظم و آماری قرار می‌گیرند و هر یک اطلاعات خاصی مثل نظم کلی تصویر، کانترست و اختلاف بالاترین سطح خاکستری و پایین‌ترین آن در تصویر و درنهایت همبستگی^۶ خطی و محلی پیکسل‌های تصویر در اختیار متخصصان قرار می‌دهند. برای استفاده از این معیارها لازم است ماتریسی مرسوم به ماتریس هم‌رخداد سطح خاکستری با معرفی یک همسایگی خاص تشکیل شود و این معیارها روی ماتریس تولید شده محاسبه شوند. از کتابخانه‌هایی که این روش‌ها را پیاده‌سازی کرده و قابلیت استفاده از آنها را در زبان برنامه‌نویسی پایتون برای متخصصان فراهم آورده است می‌توان به Skimage اشاره کرد.

واژه‌های کلیدی:

ماتریس هم‌رخدادی سطح خاکستری، استخراج ویژگی بافت‌ها، معیارهای آماری، پردازش تصویر دیجیتال

¹ Texture Feature Extraction

² Statistical Method

³ Structural Method

⁴ Spectral Method

⁵ Robert M. Haralick

⁶ Correlation

صفحه	فهرست مطالب
أ.....	چکیده.....
3.....	۱. فصل اول مقدمه.....
5.....	۲. فصل دوم تعاریف اصلی و تئوری.....
6.....	۱-۲- معرفی، تعریف، تشکیل ماتریس های هم رخدادی سطوح خاکستری.....
12.....	۲-۲- محاسبات و بررسی معیار های سنجش بافت.....
13.....	۱-۲-۲- گروه کانترست.....
16.....	۲-۲-۲- معیار های مرتب با نظم.....
18.....	۲-۲-۳- توصیف کننده های آماریم ماتریس هم رخداد.....
22.....	۳. فصل سوم پیاده سازی و بررسی نتایج.....
24.....	۳.۱. Import Libraries.....
25.....	۳.۲. Receive Images.....
25.....	۳.۳. Display Groups.....
26.....	۳.۴. Generate GLCM's.....
28.....	۳.۵. Extract Grayprops.....
29.....	۳.۶. Results.....
33.....	۴. فصل چهارم جمع بندی و نتیجه گیری.....
35.....	منابع و مراجع.....

۱. فصل اول

مقدمه

در سخنان روزمره خود تا کنون پیش آمده که بار ها اقدام به توصیف یک سطح کرده ایم، بار ها از لغات های نرم، سخت، سفت و ... برای توصیف بافت^۱ ها استفاده کرده ایم، اما در زبانی دقیق تر اگر اقدام به تعریف یا توصیف یک سطح بکنیم در میابیم که هر سطح یک بافت توپوگرافیکال^۲ است که از نقاط پست و بلند تشکیل شده است و به یک مقیاس برای برچسب گذاری میزان اختلاف پستی و بلندی های سطح و دور و نزدیکی رخداد آنها (مثل یک بند انگشت) نیازمندیم.

برای مثال یک سطح زبر و سخت^۳ درنظر گرفته می شود هرگاه:

- نسبت به یک بند انگشت اختلاف زیادی بین پستی و بلندی های سطح رخ داده باشد.
- فاصله ی بین نقاط پست و بلند نسبت به مقیاس یک بند انگشت زیاد قابل توجه باشد.

در اینصورت با یک بافت سخت سروکار خواهیم داشت.



یک سطح نرم^۴ درنظر گرفته می شود هرگاه:

- نسبت به یک بند انگشت اختلاف کمی بین پستی و بلندی های سطح رخ دهد.
- فاصله ی بین نقاط پست و بلند قابل توجه نباشد.

در اینصورت با یک بافت نرم سروکار داریم.

¹ Texture

² Topographical

³ Rough

⁴ Smooth



حال توصیف بافت تصاویر استدلالی مشابه دارد ولی با این فرق که بجای اختلاف عمق برای تشخیص نقاط پست و بلند در سطح با مقدار عددی هر پیکسل (Gray scale) سروکار خواهیم داشت و بجای معیار و مقیاسی مثل بند انگشت به پنجره یا تعریف یک همسایگی نیاز داریم.

به طور کلی برای توصیف بافت های تصویر سه رویکرد موجود است که شامل:

1. رویکرد آماری¹
2. رویکرد ساختاری²
3. رویکرد طیفی³

هستند. در این پروژه هدف ما بررسی ماتریس های هم رخدادی به عنوان یک رویکرد آماری در توصیف بافت تصاویر می باشد.

رویکرد های آماری یکی از ساده ترین رویکرد ها در توصیف بافت ها هستند که ایده های اولیه و تعاریف رسمی آن برای اولین بار توسط رابرت هارالیک⁴ در دهه ۷۰ میلادی مطرح شد. او در مقاله مربوطه ۱۴ معیار را برای تحلیل های آماری تصاویر مطرح کرده است که در این پروژه به مهمترین آنها بسنده شده است.

¹ Statistical Approaches

² Structural Approaches

³ Spectral Approaches

⁴ Robert Haralick

۲. فصل دوم

تعاریف اصلی و تئوری


۱-۲- معرفی، تعریف، تشکیل ماتریس های هم رخدادی سطوح خاکستری

در تعریفی کلی، GLCM یک جدول برای نگهداری تعداد رخداد ترکیب های مختلف سطوح خاکستری^۱ (مقدار عددی یک پیکسل) اطلاق می شود.

در پردازش تصویر تحلیل های آماری از هیستوگرام ها روشی بسیار اولیه برای تحلیل گروهی از پیکسل هایی است که در تعریف یک جهتگیری صدق کرده اند، استفاده می شوند. جهتگیری^۲ می تواند جهت های شرق و غرب و شمالی و جنوبی در تصویر باشند (همانند یک قطب نما) ولی این تعریف اطلاعات بسیار کمی از تصویر در اختیار ما قرار می دهد، لذا نیازمند تعریف همسایگی ای هستیم که به صورت نسبی مشخص شوند و کل تصویر را پوشش دهند تا بتوانیم اطلاعات دقیقی از تصویر در دست داشته باشیم و تحلیل های مناسب تری انجام دهیم، به همین دلیل این ماتریس های هم رخدادی معرفی شده اند.

در این قسمت سعی می شود با تعریف مثالی ساده، مرحله به مرحله تعاریف دقیق تر و تحلیل های بیشتری به عمل بیاوریم.

برای شروع تصویر یک کاناله زیر را در نظر بگیرید:



هر پیکسل در این تصویر از ۲ بیت تشکیل شده است، بدین معنی است که در حالت کلی ۴ سطح خاکستری در دسترس داریم که از ۰ تا ۳ طبقه بندی می شوند و هر قدر مقدار یک پیکسل به ۳ نزدیک تر باشد آن پیکسل به سفیدی میل می کند. (در ادامه بیشتر در این باره بحث خواهد شد.)

مقادیر عددی پیکسل های تصویر بالا نیز به شرح زیر می باشند:

^۱ Gray Levels

^۲ Directions

0	0	1	1
0	0	1	1
0	2	2	2
2	2	3	3

-تعریف مرتبه^۱:

مرتبه معیار های تحلیل تصاویر به میزان دخالت ارتباط بین پیکسل ها در محاسبات می باشد. دقت کنید که نباید این تعریف را با مرتبه چندجمله ای ها که بزرگترین درجه آن است اشتباه بگیریم. برای مثال معیار های مرتبه دوم به معیار هایی گفته می شود که برای تحلیل و محاسبات از گروه های دوتایی پیکسل ها استفاده می کنند (همانند Covariance). معیار های مرتبه اول به معیار هایی اطلاق می شود که تنها از مقادیر تصویر اولیه برای تحلیل استفاده می شود و هیچ همسایگی و ارتباطی بین پیکسل ها در محاسبات دخالت داده نمی شود مانند واریانس. معیار های مرتبه سوم یا بالاتر به معیار هایی گفته می شود که از گروه های سه یا بیشتر پیکسل ها برای محاسبات استفاده می شود.

- ارتباط فضایی بین دو پیکسل^۲:

ماتریس های GLCM به طور همزمان ارتباط بین دو پیکسل را در نظر میگیرند، یک پیکسل پایه^۳ و دیگری پیکسل همسایه^۴. در تعریف و ساخت ماتریس های هم رخدادی، نیاز است که یک همسایگی و ارتباط فضایی برای یافتن پیکسل های پایه و همسایه تعریف شود و بر اساس آن در تصویر میزان رخداد محاسبه شود که آن را با اپراتور Q نمایش میدهند.

اکنون که این موضوع را متوجه شده ایم میتوانیم به تعریف دقیق و ریاضیاتی ماتریس GLCM بپردازیم:

¹ Order

² Spatial Relationship

³ Reference

⁴ Neighbor

Q را به عنوان اپراتور همسایگی معرفی میکنیم و نوع همسایگی را در آن مشخص میکنیم، حال بگذارید G ماتریس مدنظر ما باشد، همچنین پیکسل های تصاویر ما سطوحی بین ۱ تا L داشته باشند و تصویر اولیه ما f باشد، در اینصورت درایه $[i, j]$ به میزان رخداد پیکسل هایی در تصویر با سطوح خاکستری Z_i و Z_j که مقادیر آنها بین ۱ تا L می باشد و تحت اپراتور Q با یکدیگر همسایه هستند، اشاره می کند. برای مثال در همان تصویر اولیه خود با تعریف اپراتور Q به شکل یک ارتباط^۱ مثل (1, 0)، همسایگی را به صورت یک پیکسل در جهت مثبت محور x معرفی میکنیم و ۰ پیکسل در جهت y معرفی میکنیم. که بعضی از همسایگی های تحت این تعریف را میتوانیم در مثال اولیه خود ببینیم:

0	0	1	1
0	0	1	1
0	2	2	2
2	2	3	3

حال مرحله به مرحله شروع به ساخت ماتریس هم رخدادی میکنیم.

در ماتریس هم رخدادی، ردیف ها نشان دهنده سطوح خاکستری مختلف به عنوان پیکسل های پایه هستند و ستون ها نمایش دهنده ی سطوح خاکستری مختلف پیکسل هایی هستند که تحت اپراتور Q به عنوان همسایه های پیکسل های پایه معرفی شده اند و مقدار هر درایه میزان رخداد این همسایگی با میزان های مشخص شده در تصویر می باشد، برای مثال درایه ی $G[0, 1] = 2$ بیان می کند که اگر پیکسل هایی با سطوح خاکستری ۰ را به عنوان پیکسل های پایه در نظر بگیرید، در اینصورت تعداد همسایگی و رخداد آنها با پیکسل هایی با سطح خاکستری ۱ که تحت Q در مجموعه همسایگی پیکسل های پایه قراره گرفته اند، برابر با ۲ خواهد بود.

¹ Relation

neighbour pixel value ->	0	1	2	3
ref pixel value: ↓				
0		<input checked="" type="checkbox"/>		
1				
2				
3				

در تصویر بالا می‌توانید نحوه بررسی و پر کردن ماتریس هم‌رخدادی را به صورت شماتیکی مشاهده کنید.

neighbour pixel value ->	0	1	2	3
ref pixel value: ↓				
0	0,0	0,1	0,2	0,3
1	1,0	1,1	1,2	1,3
2	2,0	2,1	2,2	2,3
3	3,0	3,1	3,2	3,3

برای مثال در تصویر بالا درایه واقع در بالا سمت چپ بیان می‌دارد که چه تعداد ترکیب 0,0 رخ داده است، به عبارت دیگر میزان قرار گیری پیکسل‌های سطح ۰ در همسایگی ای در Q معرفی شده است با پیکسل‌هایی که سطح ۰ دارند، چه تعداد است.

حال به ازای هر تعریف همسایگی جدید، به یک ماتریس هم‌رخدادی جدید و متفاوت نیز خواهیم رسید. در آخر نیز ماتریس هم‌رخدادی ما به فرم زیر خواهد شد:

neighbour pixel value -> ref pixel value:	0	1	2	3
0	2	2	1	0
1	0	2	0	0
2	0	0	3	1
3	0	0	0	1

دقت کنید که این ماتریس تنها فرکانس و تعداد رخداد را نگهداری میکند و هیچ ارتباطی با مقادیر اولیه پیکسل ما ندارد.

-خواص ماتریس هم رخداد سطح خاکستری:

1. این ماتریس مربعی است: پیکسل های پایه در همان بازه ای تغییر میکنند که پیکسل های همسایه تغییر میکنند، به عبارتی دیگر، تعداد ستون ها و سطرها هر دو در بازه $[1, L]$ تغییر میکنند که L بالاترین سطح خاکستری ای است که هر پیکسل میتواند اختیار کند، برای مثال در تصویر مثال ما ۲ بیت داشتیم پس بالاترین مقدار ممکن ۳ خواهد بود، حال اگر هر برای نمایش هر تصویر ۱۶ بیت داشته باشیم، سایز ماتریس ما $65336 * 65336$ خواهد شد. نکته قابل توجه این است که در واقعیت و در محاسبات واقعی حتی اگر بیت های زیادی برای نمایش تصاویر در دسترس باشد ولی حتما یک نگاشت از مقادیر پیکسل های اولیه به فضایی محدود تر صورت میگیرد تا حجم محاسبات کمتر شود، چرا در صورتی که از ماتریس بزرگی که تصاویر ۱۶ بیتی تولید میکنند استفاده کنیم، تعداد درایه های ۰ زیاد خواهد شد که نشان از بیهودگی حجم محاسبه دارند.

2. ما می خواهیم ماتریس مدنظر در اطراف قطر متقارن باشد: می دانیم که ماتریس متقارن به ماتریسی گفته می شود که $A^T = A$. یعنی درایه های (i, j) آن برابر با (j, i) باشند. در مثال مورد بررسی ماتریس تولیدی ما متقارن نخواهد بود، چرا که همسایگی آن دقیقا پیکسل های راست پیکسل های پایه درنظر گرفته می شوند، لذا درایه $(2, 3)$ مقداری برابر با $(3, 2)$ نخواهد داشت، برای متقارن شدن ماتریس باید هر شمارش دوبار صورت بگیرد: یکبار به سمت جلو^۱ یعنی ترکیب پیکسل پایه و همسایه را همانطوری که هست

¹ Forward

بشماریم) و یکبار به سمت عقب^۱ (یعنی ترکیب پیکسل پایه و همسایه را جا به جا کنیم و آن را یک رخداد در نظر بگیریم) در اینصورت ماتریس نهایی متقارن می‌شود. تقارن را می‌توان به حالتی دیگر نیز تعریف کرد، اگر همسایگی را $(1, 0)$ در نظر گرفتیم که پیکسل های شرقی را می‌شمارد، بار دیگر $(-1, 0)$ را همسایگی در نظر بگیریم که پیکسل های غربی را می‌شمارد، به چنین ماتریسی، ماتریس افقی^۲ گفته می‌شود. توجه کنید که متقارن کردن یک ماتریس ما را از مشکل پیکسل های لبه^۳ ای در پنجره تصویرمان نجات می‌دهد، در همسایگی ای که تعریف کرده ایم، پیکسل های لبه چپ هیچگاه فرصت پیکسل همسایه شدن را ندارند و پیکسل های لبه راست هیچگاه فرصت پیکسل پایه شدن را ندارند، لذا متقارن کردن ماتریس این فرصت را فراهم می‌آورد که هر پیکسل در تصویر هر حالت پایه و همسایه شدن را تجربه کند. یک راه ساده ی دیگر برای متقارن کردن ماتریس این است که ماتریس حاصل شده را با ترانزپوز^۴ آن جمع کنیم.

اثبات:

$$B = A + A^T \Rightarrow B^T = (A + A^T)^T = A^T + A$$

و می‌دانیم که جمع خاصیت جا به جایی دارد پس ماتریس B ماتریسی متقارن خواهد شد.

-تبدیل ماتریس هم رخداد به تقریبی از ماتریس احتمال:

برای توصیف هر درایه به عنوان احتمال رخداد (به جای تعداد رخداد) کافی است که مقدار هر درایه را که تعداد رخداد ترکیب سطح خاکستری ردیف و ستون را نشان می‌دهد بر تعداد کل رخداد ها تقسیم کنیم:

$$P_{i,j} = \frac{V_{i,j}}{\sum_{i,j=0}^{N-1} V_{i,j}}$$

¹ Backward

² Horizontal Matrix

³ Edge

⁴ Transpose

دقت کنید از آنجایی که در نگهداری ماتریس های هم رخداد از مقادیر گسسته از هم استفاده میکنیم که اعدادی صحیح هستند، نامیدن ماتریس حاصل شده به عنوان ماتریس احتمال اقدام دقیق علمی ای نیست، لذا صحیح است که این عملیات را نرمال سازی^۱ بنامیم.

در نهایت با نرمال سازی ماتریس تشکیل شده از بررسی مثال به ماتریس نرمال شده زیر خواهیم رسید:

.166 (4/24)	.083 (2/24)	.042 (1/24)	0 (0/24)
.083	.166	0	0
.042	0	.250	.042
0	0	.042	.083

دقت کنید که این ماتریس نیز متقارن سازی نیز شده است.

دقت کنید که اگر مقادیر روی قطر به یک نزدیک باشند، یعنی مقادیر هر پیکسل پایه و همسایه آن

نزدیک به همدیگر بوده و نشان از اختلاف^۲ کم پیکسل های تصویر نسبت به یکدیگر میدهد.

۲-۲- محاسبات و بررسی معیار های سنجش بافت^۳

معیار های سنجش بافت توابعی هستند به فرم: $f: L^2 \rightarrow R$ که L بالاترین سطح خاکستری ممکن است. در اصل معیار ها با دریافت ماتریس هم رخداد و محاسبه مربوطه، یک مقدار عددی به پنجره اعمال شده بر تصویر نظیر می کند که یک ویژگی خاص مثل رندوم بودن، یکدستی و ... را در تصویر نشان میدهد.

¹ Normalization

² Contrast

³ Texture Measure Calculations

قبل از شروع به بحث بررسی معیار های سنجش خوب است یک یادآوری از درجه و مرتبه یک معیار داشته باشیم: گفتیم که به سائز گروه های پیکسلی برای محاسبات آماری، درجه یک معیار گفته می شود، برای مثال معیار های درجه معیار هایی هستند که گروه های دو پیکسلی را برای محاسبه در نظر میگیرند مثل کوواریانس^۱. به معیار های درجه یک، معیار هایی هستند که از تنها از مقدار موجود در ماتریس استفاده می کنند، مثل واریانس.

۱-۲-۲- گروه کانترست^۲

قبل از شروع لازم به شرح است که کانترست به میزان اختلاف بین بزرگترین سطح خاکستری در پیکسل های تصویر و کوچکترین آن است، در شکل زیر می توانید تفاوت کانترست را در تصویر مشاهده کنید:



Low Contrast Image



High Contrast Image

-معیار کانترست:

در ابتدا خوب است بدانیم که برای محاسبه معیار هایی که به کانترست وابسته هستند از وزن هایی برای درایه های ماتریسمان استفاده می کنیم که براساس دوری از قطر ماتریس افزایش خوبی داشته باشند، چرا که قطر ماتریس هم رخداد تعداد رخداد های هم مقدار پیکسل ها در تصویر را نشان میدهد (کانترست پیکسل هایی که قطر را تشکیل داده اند صفر است) و دوری از قطر به معنی اختلاف در مقادیر

¹ Covariance

² Contrast measure

است و می‌دانیم دوری از قطر اصلی تاثیر بیشتری در محاسبه کانترست یک ماتریس دارد، به طوری که هرچه مقادیر دور از قطر بیشتر باشند یعنی تصویر دارای اختلاف و کانترست بیشتری می‌باشد.

پس رابطه کانترست به فرم زیر تبدیل می‌شود:

$$\sum_{i,j=0}^{N-1} P_{i,j} (i - j)^2$$

واضح است که مقادیر روی قطر کانترست ۰ داشته و با دوری از قطر اصلی مقادیر ماتریس تاثیر بیشتری در افزایش کانترست دارند. برای مثال وقتی اختلاف مقادیر درایه‌ها ۲ است، در محاسبه ی کانترست از وزن ۴ برای این درایه‌ها استفاده می‌شود.

Contrast weights:				X	horizontal GLCM				=	Multiplication result			
0	1	4	9		0.166	0.083	0.042	0		0	0.083	.168	0
1	0	1	4		0.083	0.166	0	0		0.083	0	0	0
4	1	0	1		0.042	0	.249	0.042		.168	0	0	.042
9	4	1	0		0	0	0.042	0.083		0	0	.042	0

در ماتریس چپ می‌توانید وزن‌های تاثیر گذار در محاسبه ی کانترست را مشاهده کنید که در مقادیر ماتریس متقارن و افقی ما ضرب شده و ماتریس کانترست نهایی را بوجود آورده، حال با جمع تمام مقادیر این ماتریس مقدار نهایی کانترست بدست می‌آید: 0.586

-معیار عدم تشابه:^۱

یک معیار دیگری که در گروه کانترست جای می‌گیرد معیار عدم تشابه است.

تنها تفاوت آن با کانترست، وزن‌ها به صورت خطی رشد میکنند، یعنی به ازای دوری از قطر اصلی وزن‌های تاثیر گذار در درایه‌های ماتریس هم رخداد به صورت 0, 1, 2, 3, ... خواهند بود.

¹ Dissimilarity Measure

$$\sum_{i,j=0}^{N-1} P_{i,j} |i-j|$$

-معیار همگنی^۱:

معیار بعدی قرار گرفته در این گروه، همگنی خواهد بود.

وزن دهی این معیار بدین صورت است که مقادیر روی قطری اصلی وزن ۱ داشته و با فاصله از قطر اصلی وزن ها به صورت نمایی کاهش میابند، برای مثال با دور شدن سه قطر از قطر اصلی وزن های درایه های آن قطر 1/9 خواهد بود. واضح است که هرچه این معیار مقدار بیشتری را اتخاذ کند بدین این معنی است که تصویر یکدست تر و همجنس تری داریم. در ادامه میتوانیم فرمول این معیار را ببینیم:

$$\sum_{i,j=0}^{N-1} \frac{P_{i,j}}{1 + (i-j)^2}$$

1	1/2	1/4	1/9
1/2	1	1/2	1/4
1/4	1/2	1	1/2
1/9	1/4	1/2	1

در ماتریس بالا نیز می‌توانید وزن های محاسبه شده را ببینید.

¹ Homogeneity Measure

۲-۲-۲- معیار های مرتب با نظم¹

منظم بودن بدین است که اختلاف مقادیر پیکسل های قرار گرفته درون پنجره به چه میزان الگو دار و منظم هستند (به چه میزان رخداد ها قابل پیشبینی هستند)

Orderly image					Disorderly image			
1	2	3	4		3	4	2	3
1	2	3	4		1	2	3	4
1	2	3	4		2	3	4	5
1	2	3	4		4	5	6	7

در تصویر بالا می توانید تفاوت دو ماتریس منظم (در سمت چپ) و ماتریس نامنظم (در سمت راست) را مشاهده کنید، دقت کنید که کانترست این دو ماتریس یکسان هستند ولی کاملاً در نظم تفاوت دارند.

دقت کنید که در انتخاب وزن برای محاسبه ی نظم در ماتریس، میزان عام بودن یک رخداد انتخاب مناسبی است، اگر رخداد زیاد شود میزان عام بودن آن بیشتر شده و اگر کم باشد نیز میزان عام بودنش کمتر می شود و دانستیم که ماتریس هم رخدادی به تعبیری دیگر میزان عام بودن همسایگی مقادیر را نیز نشان می دهد، پس وزن هر درایه، خود آن درایه می شود.

ASM-:

گفتیم که منطقی است وزن هر درایه در ماتریس رخداد، خود همان درایه باشد (چرا که در نظم و الگودار بودن یک ماتریس میزان عام بودن ترکیب های مختلف اعضای آن می تواند وزن مناسبی باشد) پس رابطه ASM به شکل زیر خواهد شد:

$$\sum_{i,j=0}^{N-1} P_{i,j}^2$$

¹ Measures related to orderliness

بدیهی است که هر قدر تصویر قرار گرفته در پنجره منظم تر و مرتب تر باشد مقدار ASM نیز بیشتر خواهد شد.

انرژی^۱ نیز به صورت ریشه دوم ASM تعریف می شود:

$$Energy = \sqrt{ASM}$$

-انترپی^۲:

انترپی واژه ای است که از ترمودینامیک معرفی شده و در علوم مختلف پخش شده است.

انترپی به صورت زیر معرفی می شود:

دقت کنید چون $\ln(0)$ تعریف نشده است، فرض می شود که $0 \cdot \ln(0)$ مقداری برابر با 0 دارد.

$$\sum_{i,j=0}^{N-1} P_{i,j} (-\ln(P_{i,j}))$$

دقت کنید از آنجایی که $P_{i,j}$ ها احتمالاتی هستند و مقادیری بین 0 و 1 دارند پس همواره مقدار $\ln(p)$ نامثبت می باشد و هر قدر مقدار P کوچکتر باشد انترپی آن درایه بیشتر خواهد شد در نتیجه وزن آن درایه بیشتر خواهد شد و بالعکس.

در نهایت زیاد بودن این معیار، بی نظمی تصویر تحت پنجره را نشان می دهد.

برای مثال تصویر برفک تلویزیون انترپی بالایی دارد.

¹ Energy

² Entropy

۳-۲-۲- توصیف کننده های آماری ماتریس هم رخداد^۱

این دسته از توصیف کننده های ماتریس های هم رخدادی شامل معیار هایی است که در هر فرایند آماری مشاهده می کنیم، مثل میانگین، واریانس و کوواریانس و ... با اعمال و محاسبه ی این معیار ها روی ماتریس هم رخداد، اطلاعات جدیدی از همبستگی پیکسل ها بدست می آید.

- میانگین روی $GLCM$:^۲

میانگین روی $GLCM$ را نباید با میانگین مقادیر پیکسلی تصویر اشتباه گرفت، وزنی که برای محاسبه ی میانگین در نظر گرفته شده است مقدار عددی پیکسلی است که در ترکیب همسایگی درایه مد نظر حاضر شده است، پس به ازای هر ماتریس هم رخداد دو میانگین خواهیم داشت که به شرح زیر هستند:

$$\mu_i = \sum_{j=0}^{N-1} i(P_{i,j}) \quad \mu_j = \sum_{i=0}^{N-1} j(P_{i,j})$$

همانطور که می بینید در محاسبه ی میانگین ها، وزن هر درایه سطح خاکستری یکی از پیکسل های موجود در ترکیب همسایگی در نظر گرفته شده است که بستگی دارد میانگین را براساس پیکسل پایه انجام دهیم یا همسایه.

نکته قابل اهمیت این است که در ماتریس های $GLCM$ ای که متقارن تشکیل شده اند، این دو میانگین یکسان خواهند بود.

- واریانس و انحراف معیار روی $GLCM$:^۳

این روابط همانند روابط آشنای واریانس از قبل هستند با این فرق که وزن هر درایه در محاسبه واریانس مربع فاصله سطح خاکستری یکی از پیکسل های موجود در ترکیب همسایگی از میانگین ماتریس هم رخدادی می باشد.

¹ Descriptive Statistics of the GLCM texture measures

² Mean on GLCM

³ Variance and Standard deviation on GLCM

$$\sigma_i^2 = \sum_{i,j=0}^{N-1} P_{i,j} (i - \mu_i)^2 \quad \sigma_j^2 = \sum_{i,j=0}^{N-1} P_{i,j} (j - \mu_j)^2$$

$$\sigma_i = \sqrt{\sigma_i^2} \quad \sigma_j = \sqrt{\sigma_j^2}$$

فرمول های واریانس و انحراف معیار را می‌توانید در بالا مشاهده کنید.

می‌دانیم که واریانس میزان پراکندگی از میانگین را نمایش می‌دهد، واریانس دقیقا ویژگی هایی از بافت را

نمایش می‌دهد که عدم تشابه یا کانترست نمایش می‌دهند. واریانس در ماتریس هم رخدادی دقیقا همان

خاصیت هایی که واریانس در هر روش آماری دیگر دارد را داراست، تنها نکته قابل توجه این است که در

ماتریس های متقارن هم رخدادی، مقدار هر دو روش محاسبه ی واریانس یکسان است.

-Correlation measure

این معیار، میزان وابستگی خطی پیکسل های همسایه را بررسی می‌کند و فرمول آن به شرح زیر است:

$$\sum_{i,j=0}^{N-1} P_{i,j} \left[\frac{(i - \mu_i)(j - \mu_j)}{\sqrt{(\sigma_i^2)(\sigma_j^2)}} \right]$$

لازم به ذکر است که متقارن بودن ماتریس هم رخدادی، با افزایش مخرج باعث کوچکتر شدن مقدار نهایی این عبارت می‌شود.


Correlation بالا میان پیکسل های همسایه، نشان دهنده همبستگی و وابسته خطی بودن مقادیر آنها

نسبت به یکدیگر و در نهایت نشان دهنده الگو دار بودن و قابل پیشبینی بودن بافت تصویر است.

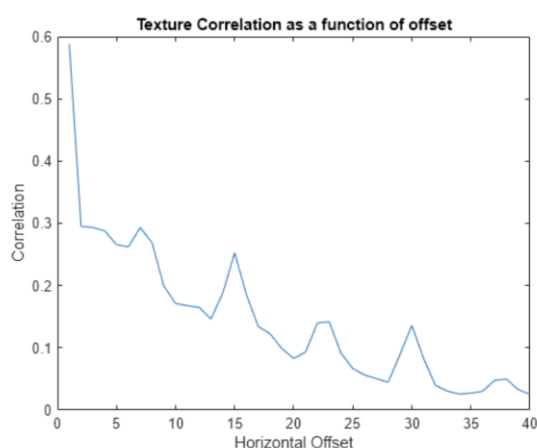
از نکات قابل توجه می‌توان به موارد زیر اشاره کرد:

- پیکسل های نزدیک به یکدیگر ضریب همبستگی بیشتری نسبت به پیکسل های دورتر دارند.
- یک پچ¹ از یک آبجکت در تصویر همبستگی بالاتری نسبت به یک پچ شامل دو آبجکت مختلف دارد.
- اگر سایز پنجره ای که روی تصویر قرار دارد به طور صعودی افزایش یابد و به ازای هر پنجره ضریب همبستگی محاسبه شود، در بازه هایی که مقادیر ضریب همبستگی نزولی می شوند، احتمالاً از ساختار یا آبجکتی وارد ساختار یا آبجکت دیگر شدیم.

برای مثال با اعمال عملیات گفته شده روی تصویر زیر:



به نمودار زیر می‌رسیم:



¹ Patch

همانطور که می‌بینید فاصله ی بین هر ماکسیمم محلی دقیقاً فاصله ی بین دو جز تشکیل دهنده مدار است که در تصویر به صورت ۷ پیکسل تکرار می‌شوند.

دقت کنید که ماتریس هم رخدادی حاصل افقی در نظر گرفته شده و مقادیر آفست که همسایگی Q را تعیین میکند در محور x در حال نمایش است.


به عنوان نکته آخر نیز قابل ذکر است که این معیار نسبت به باقی معیار ها مستقل است و به تنهایی میتواند اطلاعات خوبی از ساختار بافت ها توصیف کند.

۳. فصل سوم


پیاده سازی و بررسی نتایج

هدف از این فصل پیاده سازی تئوری های بررسی شده با استفاده از کتابخانه Skimage در زبان پایتون است. در این فصل بر آنیم تا ۵ تصویر مختلف از نظر جنس و بافت سطح را بررسی کنیم و سه گروه اطلاعات آماری فصل قبل را در این ۵ تصویر مقایسه کنیم.

پنج تصویر موجود را به دو گروه تقسیم میکنیم که مقایسه کردن راحتتر صورت بگیرد:



همانطور که می بینید گروه اول شامل سه تصویر است که از منظم ترین و الگو دار ترین تصویر (وسط) تا رندوم ترین و بدون الگو ترین تصویر (تصویر سمت راست) و در آخر تصویری میان آن دو (چپ) می باشد.



گروه دوم نیز به بررسی دو تصویر از بافت های نرم و سخت می پردازد.

قبل از شروع توضیحات پیاده سازی و نتایج، شما میتوانید از لینک قرار گرفته در منبع [1] به فایل Jupyter آن دسترسی داشته باشید.

۳.۱. Import Libraries

همانطور که گفتیم هدف استخراج اطلاعات آماری از ماتریس های هم رخدادی مورد بررسی پنج تصویر نمونه است، برای اینکار باید کتابخانه های لازم را به پروژه اضافه کنیم:

```
from google.colab import drive
from PIL import Image
import numpy as np
from skimage.feature import graycomatrix, graycoprops
from skimage.color import rgb2gray
import requests
from skimage.color import rgb2gray, rgba2rgb
from skimage.filters.rank import entropy
import matplotlib.pyplot as plt
import matplotlib.image as mpimg
from skimage.morphology import disk
```

کتابخانه ای که به ما قابلیت استفاده از ماتریس های هم رخداد و ویژگی های آماری آن در زبان پایتون را می دهد skiamge نام دارد که لازم به ذکر است که این کتابخانه در ورژن های اولیه ی خود است. همچنین برای تبدیل تصاویر به آرایه های قابل استفاده از کتابخانه معروف numpy استفاده میکنیم.

۳.۲: Receive Images

این بخش نیز پس از اجرا تصاویر نمونه را دانلود کرده و در سشن^۱ شما ذخیره میکند که تا آخر پروژه بتوانیم با آن سروکار داشته باشیم.

```
circuit_file_id = '11-c-JbKJf1XXWsvMMAAJfrMh8rzYmLa'
circuit_url = f'https://drive.google.com/uc?id={circuit_file_id}'

rough_file_id = '1LmzfcacPB3jHlWP0LQsAab7hUG7srQwK'
rough_url = f'https://drive.google.com/uc?id={rough_file_id}'

smooth_file_id = '1VSs4d8n6qo0ZaXjm3Kv3RkS2_SIDh-U2'
smooth_url = f'https://drive.google.com/uc?id={smooth_file_id}'

periodic_file_id = '1LXqshoVIsmi6KpDA_dwl-icX7i0SSu3T'
periodic_url = f'https://drive.google.com/uc?id={periodic_file_id}'

random_file_id = '1s4VKPNcoNd5nxYo5AAfGJ9wY62zPyk4h'
random_url = f'https://drive.google.com/uc?id={random_file_id}'

def get_file(url, name, format):
    response = requests.get(url)
    if response.status_code == 200:
        with open(f'{name}.{format}', 'wb') as f:
            f.write(response.content)

get_file(circuit_url, 'Circuit', 'png')
get_file(rough_url, 'Rough', 'jpg')
get_file(smooth_url, 'Smooth', 'png')
get_file(periodic_url, 'Periodic', 'png')
get_file(random_url, 'Random', 'png')
```

۳.۳: Display Groups

این بخش نیز با استفاده از کتابخانه Matplotlib گروه تصاویر را نمایش می‌دهد که نتیجه آن را در ابتدای فصل مشاهده کردیم.

^۱ Seasion

```

smooth = mpimg.imread('Smooth.png')
rough = mpimg.imread('Rough.jpg')
circuit = mpimg.imread('Circuit.png')
periodic = mpimg.imread('Periodic.png')
random = mpimg.imread('Random.png')

fig, axs = plt.subplots(1, 3, figsize=(15, 5))

for ax, img, title in zip(axs, [circuit, periodic, random], ['Mixed', 'Periodic', 'Random']):
    ax.imshow(img)
    ax.set_title(title)
    ax.axis('off')
    ax.set_aspect('equal')

plt.tight_layout()
plt.show()

```

۳.۴. Generate GLCM's

این بلاک از کد ماتریس هم رخدادی را برای تصاویر مختلفمان تولید میکند. قبل از شروع تولید ماتریس های مد نظر، ابتدا باید مطمئن شویم فرم ماتریس های تصاویرمان، فرمی درست دارند، درست بدین معنی که با متد های کتابخانه Skimage سازگار باشند.

```

smooth_gray = (255*rgb2gray(rgba2rgb(smooth))).astype(np.uint8)
rough_gray = (255*rgb2gray(np.array(rough))).astype(np.uint8)
circuit_gray = (255*rgb2gray(rgba2rgb(circuit))).astype(np.uint8)
periodic_gray = (255*rgb2gray(rgba2rgb(periodic))).astype(np.uint8)
random_gray = (255*rgb2gray(rgba2rgb(random))).astype(np.uint8)

```

در مثال اول پروژه گفتیم که فرض میکنیم تصاویر ما با ۲ بیت ذخیره می شوند، بدین معنی که بیشترین مقداری که هر پیکسل میتواند اتخاذ کند ۳ است و کمترین آن ۰، یعنی هر پیکسل ۴ مقدار مختلف میتواند بگیرد، حال از آنجایی که میخواهیم مطمئن شویم هر پیکسل ما نهایتاً مقدار ۲۵۵ اتخاذ میکند از `astype(np.uint8)` به معنای `unsigned 8 bit integer` هر درایه را تغییر تایپ میدهیم. در اصل برای نمایش ۲۵۶ مقدار مختلف، ۸ بیت کفایت خواهد کرد.

از طرفی بعضی از تصاویر ما ۴ کاناله بوده و به صورت `rgba` ذخیره شده اند، قبل از استفاده از تابع `rgb2gray` که برای خاکستری کردن تصاویر استفاده میشود، ابتدا `rgba2rgb` را به روی تصویر مدنظر فراخوانی میکنیم.


در نهایت نیز ممکن است تصاویر ما نرمال شده باشند و مقادیر آنها بین ۰ و ۱ باشند، پس آنها را در ۲۵۵ ضرب میکنیم تا به فرم عادی یک تصویر برسیم، در آخر به ازای هر تصویر یک آرایه با فرمت مناسب برای فراخوانی تابع ساخت ماتریس هم رخدادی به روی آنها، خواهیم داشت.

برای رعایت اصول Clean code یک تابع به نام `make_glcmm` پیاده سازی میکنیم:

```
# Generate GLCM
distances = [2] # Offset
angles = [np.pi/2 * 0]

def create_glcmm(gray_image, distances, angles):
    glcm = graycomatrix(gray_image, distances=distances, angles=angles, levels=256, symmetric=True, normed=True)
    return glcm
```

تابع `graycomatrix` از کتابخانه `skimage` همان چیزی است که از نظر تئوری بررسی کرده ایم، گفتیم که یک اپراتور مثل `Q` داریم که همسایگی را تعریف میکند. حال برای معرفی `relation` همسایگی باید دو آرگومان `distances`, `Angles` را مقدار دهی کنیم.



دقت کنید که `Pixel-of-interest` همان پیکسل رفرنس و پایه است.

`Angles` به صورت ضربی از π باید باشد (ورودی آن برحسب رادیان است) و `distances` میزان `offset` را مشخص میکند، در اصل میتوان زوایا را حذف کرد و فقط با `offset` همسایگی ها را مشخص کنیم برای مثال $\text{angles} = \frac{\pi}{4}$, `distances = 1` را میتوان همانطور که از تصویر بالا مشخص است به صورت `offset=[1, 1]` مشخص کرد.

آرگومان `symmetric` نیز مقادیر `Boolean` دریافت کرده و همانند متقارن سازی ای که پیش تر توضیح دادیم خروجی میدهند.

و در نهایت آرگومان `Normmed` نیز، همان فرایند نرمالایز کردن ماتریس برای نگاشت درایه ها شبیه به مقادیر احتمالاتی بین صفر و یک بوده و مقداری `Boolean` دریافت میکند.

Levels نیز بالاترین مقداری که هرپیکسل میتواند اختیار کند را نشان میدهد.

در اصل ممکن است که بخواهیم سطوح خاکستری درایه هایمان از بین ۰ تا ۲۵۵ به ۰ تا ۷ نگاشت شوند، دانستن بالاترین حد مقادیر پیکسل، تابع را در تولید این نگاشت راهنمایی خواهد کرد. مقداری که در این پروژه برای ساخت ماتریس هم رخدادی در نظر گرفته شده است، $distances = 2$ و زاویه ۰ رادیان خواهد بود و با True کردن آرگومان های متقارن و نرمالایز کردن، در اصل ماتریسی افقی تولید میکنیم، دقت کنید که تعریف هر همسایگی جدید منجر به تولید یک ماتریس جدید خواهد شد.

۳.۵. Extract Grayprops :

حال نوبت به استخراج معیار های آماری برای تحلیل ماتریس های میرسد.

```
def run_graycoprops(glcmm, stats, gray_image):
    for prop in ['contrast', 'dissimilarity', 'homogeneity', 'energy', 'entropy', 'correlation']:
        stats[prop] = graycoprops(glcmm, prop)
    return stats

stats_smooth = run_graycoprops(glcmm_smooth, stats_smooth, smooth_gray)
stats_rough = run_graycoprops(glcmm_rough, stats_rough, rough_gray)
stats_circuit = run_graycoprops(glcmm_circuit, stats_circuit, circuit_gray)
stats_periodic = run_graycoprops(glcmm_periodic, stats_periodic, periodic_gray)
stats_random = run_graycoprops(glcmm_random, stats_random, random_gray)
```

گفتیم که سه گروه معیار های آماری داریم که هریک اطلاعات خاصی از بافت و ساختار آن را در اختیار ما قرار میدهند.

در این پروژه از هر سه گروه استفاده شده و از گروه کانترست هر سه معیار انتخاب شده و از گروه نظم نیز انرژی و انتروپی و از گروه آماری تنها همسبستگی انتخاب شده است. این معیار ها به راحتی توسط تابع graycoprops محاسبه میشود. این تابع با دریافت ماتریس هم رخدادی و نوع معیار خواسته شده اقدام به محاسبه آنها کرده و در قالب یک مقدار حقیقی آن را برمیگرداند. دقت کنید برای مرتب بودن کد تصمیم گرفتم این تابع را درون یک تابع دیگر فراخوانی کنم.

۳.۶ : Results

نتایج معیار های آماری گروه اول به شرح زیر می باشد:

First Group to compare:

GLCM Measures of Periodic Texture:

contrast: 2668.895366218236

dissimilarity: 18.983557548579974

homogeneity: 0.790268174056528

energy: 0.5540340142936618

entropy: 2.3337932842081237

correlation: 0.9110865530424683

GLCM Measures of Mixed Texture:

contrast: 3284.416492279334

dissimilarity: 28.463876609405986

homogeneity: 0.48135143948955617

energy: 0.23544498674761166

entropy: 6.072258401907648

correlation: 0.6542629001127156

GLCM Measures of Random Texture:

contrast: 7085.693963267124


dissimilarity: 64.64440889992359

homogeneity: 0.07368887809497196

energy: 0.019036193050293353

entropy: 10.076047127552435

correlation: 0.48489167508125314



اگر نتیجه را با تصویر هایشان تطبیق دهیم میتوانیم تفاسیر خوبی استخراج کنیم:

دقت کنید که تصویر شبه مدار دقیقاً چیزی میان تصویر یک نویز و یک تصویر منظم است

حال اگر به نتایج تصویر منظم و تکرارشونده نگاه کنید، میبینید که ضریب همبستگی آن مقدار بسیار بالا و نزدیک به ۱ است، این نشان میدهد که تصویر الگو دار محلی، همبستگی زیادی میان پیکسل های تشکیل دهنده همسایگی های محلی اش برقرار است در حالی که همین معیار دقیقاً برای تصویر mixed

کمتر بوده و برای تصویر random پایین ترین مقدار خود را دارد، نشان میدهد که هرچه تصویر مدنظر الگوی محلی کمتری داشته باشد همبستگی آن نیز پایین تر است.

از طرفی گفتیم برای میزان نظم و ساختار کلی و جهانی در یک تصویر از انتروپی و انرژی استفاده میکنیم، دوباره با مقایسه این دو معیار برای این سه تصویر میبینیم که تصویر Periodic بیشترین انرژی و کمترین انتروپی را داشته و بعد از آن تصویر Mixed و در نهایت Random. همانطور که میبینید انرژی تصویر رندوم بسیار کم بوده و میزان انتروپی آن تقریباً ۱۰ است، یعنی میزان هرج و مرج در تصویر رندوم مطابق با انتظار بسیار بالا است.

در نهایت برای مقایسه کانترست نیز از سه معیار استفاده میکنیم، گفتیم که کانترست در اصل میزان تفاوت در مقادیر پیکسل های تصویر را میسنجد، هرچه کانترست یک تصویر کمتر باشد، تصویر یک دست تر بوده و تفاوت زیادی در پیکسل های آن دیده نمیشود و هرچه کانترست تصویر بالاتر برود، تصویر مدنظر دارای اختلاف مقادیر پیکسلی بیش از بیش بوده که خود را به شکل غلظت رنگ ها در تصویر نشان میدهد.

حال با مقایسه این سه معیار میبینیم که در تصویر Random تعداد پیکسل هایی که اختلاف رنگی زیادی نسبت به یکدیگر دارند بسیار زیاد است که در سه معیار مطرح شده این موضوع نیز به خوبی روشن است سپس در تصویر Mixed تعداد این پیکسل ها کمی بیشتر شده و در نهایت در تصویر periodic که تعداد پیکسل های یک دست در تصویر بیشتر بوده، این سه معیار کمترین میزان خود را دارند.

همینطور گفتیم که کانترست در ماتریس هم رخدادی خود را در قطر های اطراف قطر اصلی نشان میدهد.

هرچه کانترست ماتریس کمتر باشد مقادیر اطراف قطر اصلی و خود قطر اصلی بزرگتر خواهند بود و ماتریس به قطری بودن میل میکند و هرچه کانترست ماتریس بیشتر باشد، قطر اصلی ماتریس و اطراف آن به صفر میل خواهند کرد.


-تفسیر گروه دوم:

Second Group to compare:

GLCM Measures of Smooth Texture:
 contrast: 43.82199591066373
 dissimilarity: 4.8491656335387265
 homogeneity: 0.23433727716630054
 energy: 0.07023198638452748
 entropy: 5.861933613737675
 correlation: 0.46398518742692924

GLCM Measures of Rough Texture:
 contrast: 471.02219367402745
 dissimilarity: 13.799091084945
 homogeneity: 0.10899061303899613
 energy: 0.011864135348092532
 entropy: 9.507016580752152
 correlation: 0.9205074602888466

Smooth



Rough



همانند تفسیر گروه اول، همانطور که میبینیم گروه دوم از یک سطح نرم و یکدست و یک سطح زبر و خشن تشکیل شده است، میبینیم که به دلیل یکدست بودن سطح نرم سه معیار کانترست آن بسیار کمتر از سطح زبر است. همچنین به دلیل اینکه سطح زبر، معمولا سطحی بدون الگوی کلی با پستی بلندی های قابل توجه است پس انتظار داریم که نظم در آنها کمتر باشد که خود را به صورت انترپی بالاتر و انرژی کمتر در ماتریس هم رخدادی نشان میدهد.

دقت کنید که correlation وابستگی محلی تر و نظم محلی تری را نسبت به انترپی و انرژی نشان میدهد، به طور کلی انرژی و انترپی نظم کلی یک تصویر و همبستگی نظم محلی یک تصویر را نشان میدهد، برای مثال در مقایسه این تصویر میبینیم که سطح سخت با وجود داشتن انترپی بالا، همبستگی بالاتری نسبت به سطح نرم دارد، علت این است که سطح سخت ما دارای کاملا زبر و بی نظم

نیست و دارای شبه الگوهای تکرار شونده است که باعث میشود پیکسل ها منطقه های محلی خود دارای همبستگی و رفتار خطی نسبت به دیگر پیکسل های همسایه خود داشته باشند ولی در حالت کلی بین همه ی پیکسل های تصویر الگوی کلی و بزرگتری وجود نداشته باشد.

درحالی که در سطح نرم بین پیکسل های محلی ارتباط خاصی برقرار نیست ولی به طور کلی تصویر دارای نظم بیشتری است و پیکسل ها رفتار یکدست تری از خود نشان داده اند.

پس روی هم رفته می توان سطح سخت و نرم را به صورت زیر طبقه بندی کرد:

معیار	Contrast	Dissimilarity	Homogeneity	Energy	Entropy	Correlation
سطح نرم	پایین	پایین	بالا	بالا	پایین	معمولا بالا
سطح سخت	بالا	بالا	پایین	پایین	بالا	معمولا پایین

۴. فصل چهارم

جمع‌بندی و نتیجه‌گیری

در این پروژه، از دغدغه بشر برای درک جنس سطح به شکلی اتوماتیک تر شروع کردیم و قدم به قدم با تعریف ساخت یک ماتریس هم رخدادی در تصویر و همسایگی در آن، توانستیم یک تصویر تشکیل شده از پیکسل های مختلف در سه یا چهار کانال رنگی مختلف، به ماتریسی مرتب و شبه احتمالاتی برسیم که رفتار و فرکانس ظاهر شدن مقدار هر پیکسل در همسایگی دیگر پیکسل ها برسیم. سپس با خواص این ماتریس آشنا شدیم و فهمیدیم که عملیات هایی مثل متقارن سازی و نرمال سازی این ماتریس میتواند در محاسبات و تحلیل های آماری رفتار بهتری نشان دهند. بعد از آن نوبت به معیار های آماری برای تحلیل این ماتریس رسید. دیدیم که سه گروه معیار داریم که شامل: کانتراست، نظم، آماری هستند.

دیدیم که کانتراست میزان زیاد یا کم بودن اختلاف مقادیر پیکسلی تصویر را نشان میدهد، هرچه تعداد پیکسل هایی که اختلاف مقدار دارند بیشتر باشد، جزئیات رنگی بیشتری در تصویر دیده میشود و بالعکس. دیدیم که نظم کلی و جهانی یک تصویر را میتوان با معیار های گروه نظم مثل انرژی و انتروپی نشان داد و در نهایت دیدیم وابستگی محلی پیکسل های تصویر را میتوان در همبستگی دید که نشان میدهد تصویر مدنظر چه الگو های کوچک و محلی تکرار شونده ای در خود دارد.

در نهایت این معیار را در دو گروه مقایسه کردیم و دیدیم که این سه گروه اطلاعات دقیقی از تصاویر در اختیار ما قرار میدهد. دیدیم که هرچه تصویر الگو های پیشبینی پذیر تری داشته باشد، همبستگی آن بالاتر میرود ولی ممکن است لزوماً انتروپی آن بیشتر نشود (مثل دیوار های زیر سیمانی).

در نهایت توانستیم به یک جمعبندی برای مقایسه سطوح زبر و نرم برسیم، سطوح نرم معمولاً دارای کانتراست پایین تر، همجنسی بیشتر، انتروپی کمتر، انرژی بیشتر، و معمولاً همبستگی بالاتری هستند.

در نهایت تحلیل های آماری ماتریس های هم رخداد میتوانند اطلاعات مفیدی برای مدل های یادگیری ماشین به ارمغان بیاورند و در برجسب گذاری نوع اشیا کمک شایانی بکنند.

منابع و مراجع

- [1] Maryka H.Beyer, *GLCM TEXTURE: A TUTORIAL*, 2017
- [2] Rafael C. Gonzalez, *Digital Image Processing*, 2008
- [3] [Girish Ajmera, https://medium.com/@girishajmera/feature-extraction-of-images-using-glcm-gray-level-cooccurrence-matrix-e4bda8729498](https://medium.com/@girishajmera/feature-extraction-of-images-using-glcm-gray-level-cooccurrence-matrix-e4bda8729498) [Online]
- [4] [Arian Fathi, GLCM and Texture Features, 2025](#) [Online]
- [5] [Scikit-Image/docs](#) [Online]
- [6] [Matlab/docs](#) [Online]